

---

# ПРОСТРАНСТВЕННО-ВРЕМЕННЫЕ ХАРАКТЕРИСТИКИ В ЗАДАЧЕ ДЕКОДИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ.

---

Дорин Даниил  
dorin.dd@phystech.edu

Грабовой Андрей  
grabovoy.av@phystech.edu

7 марта 2024 г.

## АННОТАЦИЯ

Исследуются пространственно-временные характеристики в задаче декодирования временных рядов с дискретным представлением времени. В качестве задачи декодирования рассматривается задача классификации сигнала. В работе проводится обзор методов классификации регистрируемого сигнала. Предлагается метод классификации временных рядов, основанный на применении Римановой геометрии. Для анализа предложенного метода проводится вычислительный эксперимент на выборке, полученной при исследовании электрической активности мозга большого числа испытуемых с применением неинвазивной электроэнцефалографии. Для увеличения объема выборки производится аугментация данных. Проводится сравнение предложенного метода с известными методами классификации электроэнцефалограмм, полученных при регистрации колебаний электрического потенциала головного мозга через покровы головы.

**Ключевые слова:** ЭЭГ · временные ряды · Риманова геометрия · пространственно-временные характеристики · декодирование · классификация

## 1 Введение

Основной целью анализа сигнала в данном исследовании является классификация *электроэнцефалограммы* или *ЭЭГ* [5, 21] — раздел электрофизиологии, изучающий закономерности суммарной электрической активности мозга, отводимой с поверхности кожи волосистой части головы, а также метод записи таких потенциалов. ЭЭГ — неинвазивный метод, то есть не требует проникновения внутрь организма или повреждения кожи или других тканей. Вместо этого, данные собираются с помощью внешних средств. В последнее время активно ведутся научные исследования, посвященные методам регистрации активности мозга и декодированию информации [18] *TODO: еще ссылок.*

Основным направлением применения этих методов являются технологии нейрокомпьютерных интерфейсов.

*TODO: ссылки* Несмотря на существование нескольких методов анализа активности мозга, таких как магнитоэнцефалография, функциональная магнитно-резонансная томография и позитронная эмиссионная томография, ЭЭГ остается ценным инструментом для мониторинга активности мозга из-за его относительно низкой стоимости и удобства для пациента.

Исследования ЭЭГ широко используются в медицинской практике для диагностики различных состояний мозга. Проведение классификации сигналов ЭЭГ играет важную роль в определении уровня болезни, выявлении эпилептических припадков, оценке состояния пациента в коме, а также для мониторинга глубокого сна [8, 19].

Относительно новой, но быстро развивающейся областью исследований ЭЭГ являются интерфейсы мозг-компьютер (BCI). Технология BCI открывает новый способ взаимодействия мозга с компьютером. Система собирает сигналы мозга, анализирует их и преобразует сигналы в команды, которые могут быть отправлены на устройство вывода для выполнения определенного действия. Это позволяет осуществлять прямую связь между мозгом и компьютером. Ключевой целью исследований BCI является разработка нового канала связи, который позволяет людям с тяжелыми нервно-мышечными нарушениями напрямую передавать сообщения из своего мозга путем анализа умственной активности. Классификация моторных образов в задаче интерфейса мозг-компьютер может быть использована, например, для управления протезами или другими устройствами с помощью мысленных команд [6, 16, 20]. Для этого проводится анализ и построение модели классификации электрических сигналов ЭЭГ, связанных с моторными образами. Такой подход позволяет людям с ограниченными возможностями управлять устройствами с использованием мысленных команд, компенсируя потерю или отсутствие нормальной моторной функции.

Две основные проблемы — это классификация и извлечение признаков из временных рядов. Рассмотрим известные методы классификации временных рядов ЭЭГ, основанные на дискретном представлении времени. Традиционные методы машинного обучения, такие как линейный дискриминантный анализ, метод опорных векторов, применяются для анализа распределения признаков и поиска гиперплоскости для разделения различных классов [7, 10]. Один из успешных методов классификации предполагает одинаковые временные интервалы и фиксированную длину последовательности. В качестве основной модели обычно применяют классические модели, например, стандартная логистическая регрессия или метод опорных векторов. Перед применением основной модели используется трансформация пространства признаков в терминах римановой геометрии [3, 4]. Подробнее остановимся на методе трансформации признакового пространства. В работе [4] метод называется **Tangent Space Mapping**. Первым этапом данного алгоритма является формирование пространства централизованных признаков.

$$\mathbf{X}_i = [\mathbf{x}_1^i, \dots, \mathbf{x}_T^i] = \begin{bmatrix} x_{1,1}^i & x_{1,2}^i & \dots & x_{1,T}^i \\ \dots & \dots & \dots & \dots \\ x_{K,1}^i & x_{K,2}^i & \dots & x_{K,T}^i \end{bmatrix} = \begin{bmatrix} ts_1 \\ \dots \\ ts_K \end{bmatrix}, i = \overline{1, N}$$

где  $ts_j$  — временной ряд с нулевым средним, полученный при измерении сигнала  $j$ -ым датчиком и последующим центрированием. Тогда ковариационная матрица для одного измерения ЭЭГ имеет вид:

$$\mathbf{R}_i = \frac{1}{T-1} \mathbf{X}_i \mathbf{X}_i^\top, \quad \mathbf{R} \in \mathbb{R}^{K \times K}, \quad i = \overline{1, N}$$

Известно, что пространство, состоящее из матриц ковариации, представляет собой Риманово многообразие [3]. В каждой точке данного риманова многообразия имеется касательная плоскость с определенным скалярным произведением на ней. Общая касательная плоскость, предназначенная для отображения всех матриц ковариации в выборке, формируется в точке среднего геометрического по римановой метрике известных ковариационных матриц. Среднее геометрическое симметричных положительно определенных матриц [12] имеет вид:

$$\mathbf{R} = \mathfrak{G}(\mathbf{R}_1, \dots, \mathbf{R}_N) = \underset{\mathbf{R}}{\operatorname{argmin}} \sum_{i=1}^N \delta_R^2(\mathbf{R}, \mathbf{R}_i),$$

где риманова метрика определяется следующим образом (геодезическое расстояние):

$$\delta_R(\mathbf{R}, \mathbf{R}_i) = \|\log(\mathbf{R}^{-1} \mathbf{R}_i)\|_F = \sqrt{\sum_{i=1}^{3N} \log^2 \lambda_i},$$

$\lambda_i$  — собственные значения матрицы  $\mathbf{R}^{-1} \mathbf{R}_i$ . В работе [3] получено, что для каждой ковариационной матрицы  $\mathbf{R}_i$  существует проекция  $\boldsymbol{\pi}_i$  на касательное пространство. Таким образом, определено отображение:

$$\operatorname{Exp}_R(\boldsymbol{\pi}_i) = \mathbf{R}_i = \mathbf{R}^{\frac{1}{2}} \exp\left(\mathbf{R}^{-\frac{1}{2}} \boldsymbol{\pi}_i \mathbf{R}^{-\frac{1}{2}}\right) \mathbf{R}^{\frac{1}{2}}$$

$$\log_R(\mathbf{R}_i) = \boldsymbol{\pi}_i = \mathbf{R}^{\frac{1}{2}} \log\left(\mathbf{R}^{-\frac{1}{2}} \mathbf{R}_i \mathbf{R}^{-\frac{1}{2}}\right) \mathbf{R}^{\frac{1}{2}}$$

После проектирования каждой ковариационной матрицы  $\mathbf{R}$  с помощью  $\log_R(\cdot)$ , получаем матрицы  $\boldsymbol{\pi} \in \mathbb{R}^{K \times K}$ . Последним этапом метода является векторизация. Процесс векторизации каждой матрицы  $\boldsymbol{\pi}$  в пространство с евклидовой метрикой — последовательная запись элементов верхнетреугольной матрицы от  $\boldsymbol{\pi}$ , где диагональные элементы имеют коэффициент 1, а недиагональные — коэффициент  $\sqrt{2}$ . Полученные вектора  $\mathbf{x}$  имеют вид:

$$\mathbf{x} = [\boldsymbol{\pi}_{1,1} \quad \sqrt{2}\boldsymbol{\pi}_{1,2} \quad \dots \quad \sqrt{2}\boldsymbol{\pi}_{1,K} \quad \boldsymbol{\pi}_{2,2} \quad \dots \quad \boldsymbol{\pi}_{K,K}]^\top, \quad \mathbf{x} \in \mathbb{R}^{K(K+1)/2}$$

На практике построение ковариационных матриц и получение их образов в касательном пространстве выполняется при помощи библиотеки **PyRiemann** [2].

## Классификация временных рядов фМРТ

*Функциональная магнитно-резонансная томография* или *fMPT* является разновидностью магнитно-резонансной томографии и основана на изменениях в токе крови, вызванных нейронной активностью мозга [9]. Эти изменения происходят не моментально, а с некоторой задержкой, которая называется временем гемодинамической ответной реакции зависимости уровня кислорода в крови и составляет 4–8 с [1]. Она возникает из-за того, что сосудистая система достаточно долго реагирует на потребность мозга в глюкозе [11].

Распространенной операцией в анализе фМРТ является маскирование: извлечение определенных вокселей из всего набора данных. Обычно извлечение проводится на основе бинарной маски мозга. Маскирование можно рассматривать как отображение, которое принимает тензор четвертого порядка с пространственными размерами  $X \times Y \times Z$  и временным измерением  $T$ , а возвращает тензор второго порядка размерности  $K \times T$ , где  $K$  — это количество оставшихся после маскирования вокселей. Причинами маскирования данных могут быть, например, исключение вокселей, не связанных с мозгом или уменьшение размерности данных путем ограничения вашего анализа одной или несколькими областями интереса [13], которые могут быть определены либо функционально, либо анатомически.

## 2 Постановка задачи

Исследуется задача декодирования временного ряда. Пусть имеется некоторый процесс (активность головного мозга):

$$\mathcal{V}(\tau), \tau \in \mathbb{R}$$

Тогда данные выборки — это регистрируемый сигнал, то есть реализация процесса  $\mathcal{V}(\tau)$ :

$$\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_T], \quad \mathbf{x}_t \in \mathbb{R}^K$$

Здесь  $K$  — число каналов.  $T$  — число измерений сигнала с частотой  $\mu$  за время  $\tau$ :

$$T = \tau\mu$$

$$\mathbf{x}_{\tau\mu} \approx \mathcal{V}(\tau)$$

### 2.1 Задача классификации отрезков регистрируемого сигнала

В данной задаче имеется выборка регистрируемых отрезков сигнала, требуется классифицировать каждый наблюдаемый временной отрезок. Введем следующие обозначения: Пусть имеется  $N$  зарегистрированных реализаций некоторого процесса:

$$\mathbf{X} = \{\mathbf{X}_1, \dots, \mathbf{X}_N\},$$

$$\mathbf{X}_i = [\mathbf{x}_1^i, \dots, \mathbf{x}_T^i], \quad \mathbf{x}_t^i \in \mathbb{R}^K,$$

$$\mathbf{Y} = [y_1, \dots, y_N]^\top, \quad y_i \in \{1, \dots, C\},$$

Здесь  $y_i$  — целевая метка класса  $i$ -го зарегистрированного сигнала.  $C$  — число классов в задаче классификации сигнала.

Имеется соответственно выборка  $\mathcal{D} = \{y_i, \mathbf{X}_i\}$ ,  $i = \overline{1, N}$ . Требуется построить отображение  $f_\theta$ , которое учитывало бы пространственно-временные характеристики между временными рядами от датчиков:

$$f_\theta : \mathbf{X} \rightarrow \{1, \dots, C\}$$

## 2.2 Задача классификации активности

В данной задаче предполагается получение классификации для каждого отсчета времени наблюдения. Пусть имеется некоторый процесс и зарегистрированная реализация данного процесса в виде дискретного числа измерений. Каждому измерению соответствует класс активности. Формально:

$$\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_T\}, \quad \mathbf{x}_t \in \mathbb{R}^K,$$

$$\mathbf{Y} = [y_1, \dots, y_T]^\top, \quad y_t \in \{1, \dots, C\},$$

Здесь  $C$  — число классов в задаче классификации активности. Выборка  $\mathcal{D} = \{y_t, \mathbf{x}_t\}_{t=1}^T$

Для набора данных, описанного выше, требуется построить отображение  $f_\theta$ , которое учитывало бы пространственно-временные характеристики между временными рядами сигнала:

$$f_\theta : \mathbf{X} \rightarrow \mathbf{Y}$$

## 2.3 Задача классификации временных рядов фМРТ

Пусть имеется  $N$  многомерных временных рядов снимков фМРТ длины  $T$ :

$$\mathbf{X} = \{\mathbf{X}_1, \dots, \mathbf{X}_N\},$$

$$\mathbf{X}_i = [\mathbf{x}_1^i, \dots, \mathbf{x}_T^i], \quad \mathbf{x}_t^i \in \mathbb{R}^{X \times Y \times Z},$$

$$\mathbf{y} = [y_1, \dots, y_N]^\top, \quad y_i \in \{1, \dots, C\},$$

где  $X, Y$  и  $Z$  — размерности воксельного изображения.  $C$  — число классов.  $y_i$  — метка класса временного ряда фМРТ снимков  $\mathbf{X}_i$ .

Имеется выборка  $\mathcal{D} = \{y_i, \mathbf{X}_i\}$ ,  $i = \overline{1, N}$ . Требуется построить отображение  $f_\theta$ :

$$f_\theta : \mathbf{X} \rightarrow \{1, \dots, C\}$$

## 2.4 Проблема сегментация временного ряда фМРТ по классам стимула

При анализе медицинских данных важно учитывать уникальные особенности анатомии и реакции каждого человека на стимулы. Для более точного декодирования этих данных необходимо обучать модель индивидуально под конкретного индивида. Такой подход помогает учитывать особенности каждого человека. В медицинских наборах данных

обычно представлено только одно большое измерение для каждого человека. Для решения конкретных задач необходимо разбить или сегментировать этот временной ряд для дальнейшего анализа. Например, разделение данных по классам стимулов позволяет более детально изучить реакцию мозга на различные воздействия, что способствует более точному анализу и разработке персонализированных методов классификации и обработки медицинских данных. Формализуем постановку проблемы сегментации непосредственно для последующей задачи классификации.

Предположим, что у нас имеется одно непрерывное измерение фМРТ с дискретным представлением времени для конкретного человека:

$$\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_T], \quad \mathbf{x}_t \in \mathbb{R}^{X \times Y \times Z},$$

где  $X, Y$  и  $Z$  — размерности тензора снимка,  $T$  — длина временного ряда. В ходе процедуры фМРТ человек выполняет зрительные, моторные или когнитивные задания различных категорий. Для удобства дальнейшего изложения мы будем говорить в парадигме зрительных стимулов.

Пусть имеется временной ряд стимулов:

$$\mathbf{s} = [s_1, \dots, s_T], \quad s_t \in \{0, \dots, C\},$$

где  $\{1, \dots, C\}$  — множество категорий зрительных стимулов. Классом 0 обозначены моменты отдыха человека. Необходимо сегментировать временной ряд на отрезки фиксированной длины  $\tau$ , чтобы в соответствующих сегментах временного ряда стимулов преобладала определенная категория. Под длиной отрезка понимаем число временных отсчетов.

### 3 Предлагаемый метод классификации временных рядов фМРТ

#### 3.1 Сегментация временного ряда по классам стимулов

Предположим имеется временной ряд фМРТ  $\mathbf{X}$  и соответствующий ему временной ряд стимулов  $\mathbf{s}$ , который содержит моменты отдыха человека:

$$\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_T], \quad \mathbf{x}_t \in \mathbb{R}^{X \times Y \times Z},$$

$$\mathbf{s} = [s_1, \dots, s_T], \quad s_t \in \{0, \dots, C\},$$

где  $X, Y$  и  $Z$  — размерности тензора фМРТ,  $T$  — длина временного ряда. Если в момент времени  $t$  значение  $q_t = k \in \{1, \dots, C\}$ , значит человек наблюдал стимул категории  $k$ . Если же  $q_t = 0$ , человек отдыхал.

Предполагаем, что человек имел возможность отдохнуть между демонстрацией стимулов разных категорий. На практике такое предположение обычно выполняется. Для каждого класса  $k \in \{1, \dots, C\}$  выделим из временного ряда  $\mathbf{X}$  сегменты фиксированной длины  $\tau$  следующим образом:

1. Находим индексы начала и конца отрезков, соответствующих классу стимулов  $k$ . Обозначим эти точки в порядке возрастания  $\{b_1, \dots, b_{n_k}\}$  и  $\{e_1, \dots, e_{n_k}\}$  соответственно, где  $n_k$  — число отрезков, соответствующих классу  $k$ . Эти точки определяются следующим образом:

$$\{b_1, \dots, b_{n_k}\} = \{t \mid s_t = k, s_{t-1} = 0\},$$

$$\{e_1, \dots, e_{n_k}\} = \{t \mid s_t = k, s_{t+1} = 0\},$$

2. Для каждого отрезка  $[b_j, e_j] \subset [1, T]$  длины  $\tau_j = e_j - b_j + 1$  добавим слева и справа сегменты отвечающие моментам отдыха испытуемого, чтобы получить отрезок фиксированной длины  $\tau$ :

$$\mathbf{X}_j = [\mathbf{x}_{b_j - \delta_1}, \dots, \mathbf{x}_{e_j + \delta_2}],$$

$$\mathbf{s}_j = [s_{b_j - \delta_1}, \dots, s_{e_j + \delta_2}],$$

где  $j = \overline{1, n_k}$ ,  $\delta_1 = \lfloor (\tau - \tau_j)/2 \rfloor$ ,  $\delta_2 = \lceil (\tau - \tau_j)/2 \rceil$  и  $\lfloor \cdot \rfloor$  и  $\lceil \cdot \rceil$  обозначают операции округления в меньшую и большую сторону соответственно.

Обратим внимание, что для каждого класса предполагается  $\tau_j < \tau$ ,  $j = \overline{1, n_k}$ .

3. В результате объединения по всем классам получим  $N = \sum_{k=1}^C n_k$  сегментов временного ряда длины  $\tau$ :

$$\mathbf{X} = \{\mathbf{X}_1, \dots, \mathbf{X}_N\},$$

$$\mathbf{X}_j = [\mathbf{x}_1^j, \dots, \mathbf{x}_\tau^j], \quad \mathbf{x}_t^j \in \mathbb{R}^{X \times Y \times Z},$$

$$\mathbf{s}_j = [s_1, \dots, s_\tau]^\top, \quad s_t \in \{0, y_j\},$$

$$\mathbf{y} = [y_1, \dots, y_N]^\top, \quad y_j \in \{1, \dots, C\},$$

где  $y_j$  — метка класса временного ряда  $\mathbf{X}_j$ .

### 3.2 Взвешивание вокселей фМРТ снимков

Снимки фМРТ представляют собой объемные многомерные наборы данных. При этом значительная доля вокселей фМРТ соответствует фоновому изображению, которое может вносить существенный шум при классификации. Кроме того, необходимо учитывать, что конкретные области мозга отвечают за выполнение определенных зрительных, когнитивных и моторных задач. Таким образом, при анализе снимков фМРТ важным аспектом является корректная локализация активных областей мозга, ответственных за выполнение конкретной задачи.

В работе предлагается новый метод cross-correlation weighting (CCW) детектирования и взвешивания активных областей мозга в задаче декодирования временных рядов фМРТ. Пусть имеется временной ряд фМРТ  $\mathbf{X}$  и соответствующий ему временной ряд стимулов  $\mathbf{s}$ :

$$\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_\tau], \quad \mathbf{x}_t \in \mathbb{R}^{X \times Y \times Z}$$

$$\mathbf{s} = [s_1, \dots, s_\tau]^\top \quad s_t \in \{0, 1\}.$$

Когда человек наблюдает стимул, значение переменной  $q_t$  равно 1, в то время как во время отдыха оно равно 0.

Результатом работы алгоритма является бинарная маска  $\mathcal{M} \in \mathbb{R}^{X \times Y \times Z}$ , в которой ненулевым значениям соответствуют области человеческого мозга, активно реагирующие на стимул.

Предложенный метод состоит из следующих этапов:

1. На вход подается временной ряд фМРТ  $\mathbf{X}$  с частотой снимков  $\mu$  и временной ряд стимулов  $\mathbf{s}$ .
2. 3D Average Pooling: Ко всем изображениям фМРТ в  $\mathbf{X}$  применяется 3D свертка  $\text{AvgPool3d}(\cdot, k_s)$  с размером ядра  $k_s$ :

$$\mathbf{X}' = [\mathbf{x}'_1, \dots, \mathbf{x}'_\tau],$$

$$\mathbf{x}'_t = \text{AvgPool3d}(\mathbf{x}_t, k_s) \in \mathbb{R}^{X/k_s \times Y/k_s \times Z/k_s},$$

где  $\mathbf{X}'$  — это сжатые данные фМРТ.

3. Z-нормализация временных рядов: временные ряды каждого вокселя в сжатых данных фМРТ  $\mathbf{X}'$  нормализуются путем вычитания их выборочного среднего и деления на выборочное стандартное отклонение. Аналогично нормализуется временной ряд  $\mathbf{s}$ . Обозначим нормализованные данные  $\hat{\mathbf{X}}'$  и  $\hat{\mathbf{s}}$  соответственно.
4. Вычисление кросс-корреляции: введем обозначение  $v_t^{i,j,k}$  — значение вокселя снимка фМРТ  $\hat{\mathbf{x}}'_t$  в позиции  $(i,j,k)$ . Тогда для каждой тройки индексов  $(i,j,k)$  определим функцию кросс-корреляции между временным рядом вокселя  $\mathbf{v}^{i,j,k}$  и временным рядом стимулов  $\hat{\mathbf{s}}$  следующим образом:

$$c_{i,j,k}(p) = (\hat{\mathbf{s}} * \mathbf{v}^{i,j,k})(p) = \sum_{t=1}^{\tau-p} \hat{s}_t v_{t+p}^{i,j,k}, \quad p = \overline{0, \tau-1}, \quad \text{где}$$

$$\mathbf{v}^{i,j,k} = [v_1^{i,j,k}, \dots, v_\tau^{i,j,k}]^\top$$

$$\hat{\mathbf{s}} = [\hat{s}_1, \dots, \hat{s}_\tau]^\top$$

5. Воспользуемся предположением наличия неизменяющегося времени гемодинамической ответной реакции зависимости уровня кислорода в крови (BOLD Delay). Считаем, что есть задержка  $\Delta t$ , которая является параметром метода. Вычислим дискретный момент времени соответствующий задержке:

$$p_{\text{BOLD}} = \lfloor \mu \Delta t \rfloor.$$



Находим значение кросс-корреляционной функции  $c_{i,j,k}(p_{\text{BOLD}})$  для каждой тройки индексов  $(i,j,k)$ . Если область мозга реагирует на стимул, то значение кросс-корреляционной функции для вокселей из этой области ожидается большим. Рассмотрим нулевой тензор  $\mathcal{M}_c \in \mathbb{R}^{X/k_s \times Y/k_s \times Z/k_s}$ . Теперь присваиваем единицы для значений тензора в позициях  $(i,j,k)$ , соответствующих  $h$  наибольшим значениям  $c_{i,j,k}(p_{\text{BOLD}})$ . В итоге получаем необходимую маску, однако сжатую.

6. Upsample: последним шагом остается выполнить операцию обратной свертки, которая позволит получить тензор  $\mathcal{M} \in \mathbb{R}^{X \times Y \times Z}$ . Здесь обратная свертка подразумевает назначение каждому элементу тензора  $\mathcal{M}_c \in \mathbb{R}^{X/k_s \times Y/k_s \times Z/k_s}$  маленького тензора размером  $k_c \times k_c \times k_c$ , значения которого совпадают со значениями элемента в  $\mathcal{M}_c$ .

Метод имеет три настраиваемых параметра: размер ядра  $k_c$ , время геомодинамической ответной реакции  $\Delta t$  и число активных областей  $h$ .

## 4 Вычислительный эксперимент


### 4.1 EEG Motor Movement/Imagery Dataset

Для анализа работоспособности предложенного метода, а также проверки гипотез проведен вычислительный эксперимент. Для проведения исследования используется набор данных Physionet [14, 15] для классификации ЭЭГ сигналов двигательных активностей, моторных образов. Записи были получены от 109 испытуемых с использованием системы VSI2000 и получены с 64 электродов в системе 10-10 [17] с частотой дискретизации 160 Гц. Каждый испытуемый выполнил 14 пробежек, включая две базовые пробежки, одну с открытыми глазами, а другую с закрытыми, каждая продолжительностью в одну минуту. После этих базовых пробежек они выполнили четыре различных задания, каждое из которых повторялось по три раза, причем каждое задание длилось две минуты.

Для проведения базового эксперимента используется подвыборка для задачи бинарной классификации состояния глаз открыты/закрыты.

### Применение Римановой геометрии


Используем подвыборку для классификации состояния глаз открыты/закрыты. Рассмотрим несколько классических методов классификации. Метод опорных векторов — один из наиболее популярных методов обучения, который применяется для решения задач классификации и регрессии. Чтобы показать преимущество перехода к Риманову касательному пространству, проведем следующий эксперимент. Векторизуем все многомерные временные ряды и обучим на полученных векторах SVM. Теперь применим алгоритм векторизации Tangent Space Mapping (TSM) на многомерных временных рядах и после этого обучим SVM на векторизованных данных. Результаты на валидации и тесте приведены в таблице 1. Качество классификации после проектирования на касательное пространство гораздо лучше.



**Рис. 1:** Regions of interest obtained as a result of cross-correlation analysis with the video sequence character

**Таблица 1:** Сравнение методов

Метод	accuracy	
	валидация	тест
SVM	0.732	0.697
TSM SVM	0.939	0.954




**Рис. 2:** Regions of interest obtained as a result of cross-correlation analysis with noise

## 4.2 UCI EEG Eye State

Набор данных бинарной классификации состояния глаз получен в результате одного непрерывного измерения неинвазивного ЭЭГ с помощью нейроголовки Emotiv EEG с использованием 14 датчиков, на рис.3 задействованные датчики изображены красным цветом.

Продолжительность измерения в выборке составила 117 секунд. Состояние глаз было зафиксировано с помощью камеры во время измерения ЭЭГ и позже добавлено вручную в файл после анализа видеок кадров. Метка «1» указывает на состояние с закрытыми глазами, а «0» — на состояние с открытыми глазами. Все значения приведены в



**Рис. 3:** Задействованные датчики ЭЭГ при измерении сигнала

хронологическом порядке с первым измеренным значением в верхней части данных. Основные характеристики выборки представлены в Таблице 2.

## 5 Заключение

**Таблица 2:** Описание выборки

Название	Обозначение	Значение
Продолжительность обследования	$\tau$	117 с
Частота измерения сигнала	$\mu$	128.03 с <sup>-1</sup>
Число каналов (датчиков)	$K$	14
Число измерений сигнала	$T$	14980

## Список литературы

- [1] Peter A. Bandettini, Eric C. Wong, R. Scott Hinks, Ronald S. Tikofsky, and James S. Hyde. Time course epi of human brain function during task activation. *Magnetic Resonance in Medicine*, 25(2):390–397, June 1992.
- [2] Alexandre Barachant. pyriemann documentation. Technical report, Tech. Rep. 0.2. 6, 2018.[Online]. Available: <https://readthedocs.org> . . . , 2018.
- [3] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. Riemannian geometry applied to bci classification. In *International conference on latent variable analysis and signal separation*, pages 629–636. Springer, 2010.
- [4] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. Multiclass brain–computer interface classification by riemannian geometry. *IEEE Transactions on Biomedical Engineering*, 59(4):920–928, 2011.
- [5] Sándor Beniczky and Donald L Schomer. Electroencephalography: basic biophysical and technological aspects important for clinical applications. *Epileptic Disorders*, 22(6):697–715, 2020.
- [6] Aniana Cruz, Gabriel Pires, Ana Lopes, Carlos Carona, and Urbano J Nunes. A self-paced bci with a collaborative controller for highly reliable wheelchair driving: Experimental tests with physically disabled individuals. *IEEE Transactions on Human-Machine Systems*, 51(2):109–119, 2021.
- [7] Rongrong Fu, Yongsheng Tian, Tiantian Bao, Zong Meng, and Peiming Shi. Improvement motor imagery eeg classification based on regularized linear discriminant analysis. *Journal of medical systems*, 43:1–13, 2019.
- [8] Dragoljub Gajic, Zeljko Djurovic, Stefano Di Gennaro, and Fredrik Gustafsson. Classification of eeg signals for detection of epileptic seizures based on wavelets and statistical pattern recognition. *Biomedical Engineering: Applications, Basis and Communications*, 26(02):1450021, 2014.
- [9] Gary H. Glover. Overview of functional magnetic resonance imaging. *Neurosurgery Clinics of North America*, 22(2):133–139, April 2011.
- [10] Yinxia Liu, Weidong Zhou, Qi Yuan, and Shuangshuang Chen. Automatic seizure detection using wavelet transform and svm in long-term intracranial eeg. *IEEE transactions on neural systems and rehabilitation engineering*, 20(6):749–755, 2012.
- [11] Nikos K. Logothetis. The underpinnings of the BOLD functional magnetic resonance imaging signal. *The Journal of Neuroscience*, 23(10):3963–3971, May 2003.

- [12] Maher Moakher. A differential geometric approach to the geometric mean of symmetric positive-definite matrices. *SIAM journal on matrix analysis and applications*, 26(3):735–747, 2005.
- [13] Russell A Poldrack. Region of interest analysis for fmri. *Social cognitive and affective neuroscience*, 2(1):67–70, 2007.
- [14] Gerwin Schalk, Dennis J McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R Wolpaw. Bci2000: a general-purpose brain-computer interface (bci) system. *IEEE Transactions on biomedical engineering*, 51(6):1034–1043, 2004.
- [15] Gerwin Schalk, Dennis J McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R Wolpaw. "eeg motor movement/imagery dataset 2022.
- [16] Andreas Schwarz, Maria Katharina Höller, Joana Pereira, Patrick Ofner, and Gernot R Müller-Putz. Decoding hand movements from human eeg to control a robotic arm in a simulation environment. *Journal of neural engineering*, 17(3):036010, 2020.
- [17] Margitta Seeck, Laurent Koessler, Thomas Bast, Frans Leijten, Christoph Michel, Christoph Baumgartner, Bin He, and Sándor Beniczky. The standardized eeg electrode array of the ifcn. *Clinical neurophysiology*, 128(10):2070–2077, 2017.
- [18] Siuly Siuly, Yan Li, and Yanchun Zhang. Eeg signal analysis and classification. *IEEE Trans Neural Syst Rehabil Eng*, 11:141–144, 2016.
- [19] Shelagh JM Smith. Eeg in the diagnosis, classification, and management of patients with epilepsy. *Journal of Neurology, Neurosurgery & Psychiatry*, 76(suppl 2):ii2–ii7, 2005.
- [20] Yonghao Song, Weifeng Wu, Chengqi Lin, Gengliang Lin, Guofeng Li, and Longhan Xie. Assistive mobile robot with shared control of brain-machine interface and computer vision. In *2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC)*, volume 1, pages 405–409. IEEE, 2020.
- [21] Michal Teplan et al. Fundamentals of eeg measurement. *Measurement science review*, 2(2):1–11, 2002.