
ПРОСТРАНСТВЕННО-ВРЕМЕННЫЕ ХАРАКТЕРИСТИКИ В ЗАДАЧЕ ДЕКОДИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ.

Дорин Даниил
dorin.dd@phystech.edu

Грабовой Андрей
grabovoy.av@phystech.edu

26 января 2024 г.

АННОТАЦИЯ

Исследуются пространственно-временные характеристики в задаче декодирования временных рядов с дискретным представлением времени. В качестве задачи декодирования рассматривается задача классификации сигнала. В работе проводится обзор методов классификации регистрируемого сигнала. Предлагается метод классификации временных рядов, основанный на применении Римановой геометрии. Для анализа предложенного метода проводится вычислительный эксперимент на выборке, полученной при исследовании электрической активности мозга большого числа испытуемых с применением неинвазивной электроэнцефалографии. Для увеличения объема выборки производится аугментация данных. Проводится сравнение предложенного метода с известными методами классификации электроэнцефалограмм, полученных при регистрации колебаний электрического потенциала головного мозга через покровы головы.

Ключевые слова: ЭЭГ · временные ряды · Риманова геометрия · пространственно-временные характеристики · декодирование · классификация

1 Введение

Основной целью анализа сигнала в данном исследовании является классификация электроэнцефалограммы (ЭЭГ) [2, 9] — раздел электрофизиологии, изучающий закономерности суммарной электрической активности мозга, отводимой с поверхности кожи волосистой части головы, а также метод записи таких потенциалов. Также ЭЭГ — неинвазивный метод, то есть не требует проникновения внутрь организма или повреждения кожи или других тканей. Вместо этого, данные собираются с помощью внешних средств. В последнее время активно ведутся научные исследования, посвященные методам реги-

сттрации активности мозга и декодированию информации [4, 7]. Основным направлением применения этих методов являются технологии нейрокомпьютерных интерфейсов.

Исследования ЭЭГ широко используются в медицинской практике для диагностики различных состояний мозга. Проведение классификации сигналов ЭЭГ играет важную роль в определении уровня болезни, выявлении эпилептических припадков, оценке состояния пациента в коме, а также для мониторинга глубокого сна [5, 8].

Одним из успешных традиционных методов классификации наличия потенциала Р300 на электроэнцефалограмме (ЭЭГ) является алгоритм **ERPcov TS**. Под потенциалом Р300 понимается связанный с событием (event-related potential — ERP) измеренный отклик мозга, который является прямым результатом определенного ощущения, когнитивного или моторного события. Алгоритм основан на применении Римановой геометрии[1]. Первым этапом данного алгоритма является формирование пространства центрированных признаков.

$$\mathbf{X}_i = [\mathbf{x}_1^i, \dots, \mathbf{x}_T^i] = \begin{bmatrix} x_{1,1}^i & x_{1,2}^i & \dots & x_{1,T}^i \\ \dots & \dots & \dots & \dots \\ x_{K,1}^i & x_{K,2}^i & \dots & x_{K,T}^i \end{bmatrix} = \begin{bmatrix} ts_1 \\ \dots \\ ts_K \end{bmatrix},$$

где ts_j — временной ряд с нулевым средним, полученный при измерении сигнала j -ым датчиком и последующего центрирования. Тогда ковариационная матрица для одного измерения ЭЭГ имеет вид:

$$\mathbf{R}_i = \frac{1}{T-1} \mathbf{X}_i \mathbf{X}_i^\top, \quad \mathbf{R} \in \mathbb{R}^{K \times K}, \quad i = \overline{1, N}$$

Для классификации потенциала Р300 в алгоритме используется расширенная матрица ковариации:

$$\mathbf{R}_i = \frac{1}{T-1} \mathbf{P}_i \mathbf{P}_i^\top, \quad \mathbf{P}_i = \begin{bmatrix} \mathbf{X}^0 \\ \mathbf{X}^1 \\ \mathbf{X}_i \end{bmatrix},$$

где $\overline{\mathbf{X}^c}$ и $\overline{\mathbf{X}^1}$ — средние по классам $\{0,1\}$ значения:

$$\overline{\mathbf{X}^c} = \frac{\sum_{i=1}^N [y_i = c] \mathbf{X}_i}{\sum_{i=1}^N [y_i = c]}, \quad c \in \{0,1\}$$

Известно, что пространство, состоящее из матриц ковариации, представляет собой риманово многообразие[1]. В каждой точке данного риманова многообразия имеется касательная плоскость с определенным скалярным произведением на ней. Общая касательная плоскость, предназначенная для отображения всех матриц ковариации в выборке, формируется в точке среднего геометрического по римановой метрике известных ковариационных матриц. Среднее геометрическое симметричных положительно определенных матриц имеет вид:

$$\mathbf{R} = \mathfrak{G}(\mathbf{R}_1, \dots, \mathbf{R}_N) = \underset{\mathbf{R}}{\operatorname{argmin}} \sum_{i=1}^N \delta_R^2(\mathbf{R}, \mathbf{R}_i),$$

где риманова метрика определяется следующим образом (геодезическое расстояние):

$$\delta_R(\mathbf{R}, \mathbf{R}_i) = \|\log(\mathbf{R}^{-1}\mathbf{R}_i)\|_F = \sqrt{\sum_{i=1}^{3N} \log^2 \lambda_i},$$

где λ_i — собственные значения матрицы $\mathbf{R}^{-1}\mathbf{R}_i$. В работе [1] получено, что для каждой ковариационной матрицы \mathbf{R}_i существует проекция $\boldsymbol{\pi}_i$ на касательное пространство. Таким образом, определено отображение:

$$\begin{aligned} \text{Exp}_R(\boldsymbol{\pi}_i) &= \mathbf{R}_i = \mathbf{R}^{\frac{1}{2}} \exp\left(\mathbf{R}^{-\frac{1}{2}} \boldsymbol{\pi}_i \mathbf{R}^{-\frac{1}{2}}\right) \mathbf{R}^{\frac{1}{2}} \\ \log_R(\mathbf{R}_i) &= \boldsymbol{\pi}_i = \mathbf{R}^{\frac{1}{2}} \log\left(\mathbf{R}^{-\frac{1}{2}} \mathbf{R}_i \mathbf{R}^{-\frac{1}{2}}\right) \mathbf{R}^{\frac{1}{2}} \end{aligned}$$

На практике построение ковариационных матриц и получение их образов в касательном пространстве выполняется при помощи библиотеки **PyRiemann** [3].

После векторизации полученные данные используются как новое признаковое пространство и могут быть классифицированы при помощи классических методов машинного обучения.

2 Постановка задачи

Исследуется задача декодирования временного ряда. Пусть имеется некоторый процесс (активность головного мозга):

$$\mathcal{V}(\tau), \tau \in \mathbb{R}$$

Тогда данные выборки — это регистрируемый сигнал, то есть реализация процесса $\mathcal{V}(\tau)$:

$$\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_T], \mathbf{x}_t \in \mathbb{R}^K$$

Здесь K — число каналов. T — число измерений сигнала с частотой μ за время τ :

$$T = \tau\mu$$

$$\mathbf{x}_{\tau\mu} \approx \mathcal{V}(\tau)$$

2.1 Задача классификации отрезков регистрируемого сигнала

В данной задаче имеется выборка регистрируемых отрезков сигнала, требуется классифицировать каждый наблюдаемый временной отрезок. Введем следующие обозначения: Пусть имеется N зарегистрированных реализаций некоторого процесса:

$$\begin{aligned} \mathbf{X} &= \{\mathbf{X}_1, \dots, \mathbf{X}_N\}, \\ \mathbf{X}_i &= [\mathbf{x}_1^i, \dots, \mathbf{x}_T^i], \mathbf{x}_t^i \in \mathbb{R}^K, \\ \mathbf{Y} &= [y_1, \dots, y_N]^\top, y_i \in \{1, \dots, C\} \end{aligned}$$

Здесь y_i — целевая метка класса i -го зарегистрированного сигнала. C — число классов в задаче классификации сигнала.

Имеется соответственно выборка $\mathcal{D} = \{y_i, \mathbf{X}_i\}$, $i = \overline{1, N}$. Требуется построить отображение f_θ , которое учитывало бы пространственно-временные характеристики между временными рядами от датчиков:

$$f_\theta : \mathbf{X} \rightarrow \{1, \dots, C\}$$

2.2 Задача классификации активности

В данной задаче предполагается получение классификации для каждого отсчета времени наблюдения. Пусть имеется некоторый процесс и зарегистрированная реализация данного процесса в виде дискретного числа измерений. Каждому измерению соответствует класс активности. Формально:

$$\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_T\}, \mathbf{x}_t \in \mathbb{R}^K,$$

$$\mathbf{Y} = [y_1, \dots, y_T]^\top, y_t \in \{1, \dots, C\}$$

Здесь C — число классов в задаче классификации активности. Выборка $\mathcal{D} = \{y_t, \mathbf{x}_t\}_{t=1}^T$

Для набора данных, описанного выше, требуется построить отображение f_θ , которое учитывало бы пространственно-временные характеристики между временными рядами сигнала:

$$f_\theta : \mathbf{X} \rightarrow \{1, \dots, C\}$$

3 Вычислительный эксперимент

3.1 Первая постановка задачи

Для анализа работоспособности предложенного метода, а также проверки гипотез проведен вычислительный эксперимент.

Для проведения экспериментов используется набор данных [6] 64-канальных ЭЭГ сигналов от испытуемых, выполнявших серию моторных/образных задач. Набор данных предоставлен в PhysioNet разработчиками системы инструментов BCI2000 для исследований мозг-компьютерного интерфейса. Этот набор данных состоит из более чем 1500 одно- и двухминутных записей ЭЭГ, полученных от 109 волонтеров во время выполнения различных заданий.

Для проведения базового эксперимента используется подвыборка бинарной классификации состояния глаз открыты/закрыты.

3.2 Вторая постановка задачи

Для проведения экспериментов была использована выборка бинарной классификации состояния глаз. Набор данных получен в результате одного непрерывного измерения неинвазивного ЭЭГ с помощью нейроголовки Emotiv EEG с использованием 14 датчиков, на рис.1 задействованные датчики изображены красным цветом.




Рис. 1: Задействованные датчики ЭЭГ при измерении сигнала

Продолжительность измерения в выборке составила 117 секунд. Состояние глаз было зафиксировано с помощью камеры во время измерения ЭЭГ и позже добавлено вручную в файл после анализа видеок кадров. Метка «1» указывает на состояние с закрытыми глазами, а «0» — на состояние с открытыми глазами. Все значения приведены в хронологическом порядке с первым измеренным значением в верхней части данных. Основные характеристики выборки представлены в Таблице 1.

При анализе выборки обнаружено 4 выброса, которые были заменены средними по классам значениями, график временных рядов после обработки выбросов представлен на рис.2.

Таблица 1: Описание выборки

Название	Обозначение	Значение
Продолжительность обследования	τ	117 с
Частота измерения сигнала	μ	128.03 с ⁻¹
Число каналов (датчиков)	K	14
Число измерений сигнала	T	14980




Рис. 2: График временных рядов

TODO: попробовать применить библиотеку **PyRiemann** к данным.

4 Заключение

Список литературы

- [1] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. Riemannian geometry applied to bci classification. In *International conference on latent variable analysis and signal separation*, pages 629–636. Springer, 2010.
- [2] Sándor Beniczky and Donald L Schomer. Electroencephalography: basic biophysical and technological aspects important for clinical applications. *Epileptic Disorders*, 22(6):697–715, 2020.
- [3] Marco Congedo, Alexandre Barachant, and Anton Andreev. A new generation of brain-computer interface based on riemannian geometry. *arXiv preprint arXiv:1310.8115*, 2013.
- [4] Alexander Craik, Yongtian He, and Jose L Contreras-Vidal. Deep learning for electroencephalogram (eeg) classification tasks: a review. *Journal of neural engineering*, 16(3):031001, 2019.
- [5] Dragoljub Gajic, Zeljko Djurovic, Stefano Di Gennaro, and Fredrik Gustafsson. Classification of eeg signals for detection of epileptic seizures based on wavelets and statistical pattern recognition. *Biomedical Engineering: Applications, Basis and Communications*, 26(02):1450021, 2014.
- [6] Gerwin Schalk, Dennis J McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R Wolpaw. Bci2000: a general-purpose brain-computer interface (bci) system. *IEEE Transactions on biomedical engineering*, 51(6):1034–1043, 2004.
- [7] Siuly Siuly, Yan Li, and Yanchun Zhang. Eeg signal analysis and classification. *IEEE Trans Neural Syst Rehabil Eng*, 11:141–144, 2016.
- [8] Shelagh JM Smith. Eeg in the diagnosis, classification, and management of patients with epilepsy. *Journal of Neurology, Neurosurgery & Psychiatry*, 76(suppl 2):ii2–ii7, 2005.
- [9] Michal Teplan et al. Fundamentals of eeg measurement. *Measurement science review*, 2(2):1–11, 2002.